

Entrega #2-Análisis de Sentimiento de transmilenio

Resumen Ejecutivo

En esta segunda fase del proyecto integrador, se consolida el flujo analítico y experimental avanzado de **Machine Learning II** sobre el corpus oficial de reseñas ciudadanas de **TransMi[App]** (`com.nexura.transmilenio`), extraído directamente de Google Play Store para Bogotá. A diferencia de esquemas con datos simulados, esta entrega opera sobre un dataset real curado de **N = 6.089 registros** (N > 5.000), el cual reproduce de manera natural la estructura de fuerte desbalance documentada en el artículo base de Tiwari et al. (2023) (**80.57% de quejas ciudadanas / 19.43% de elogios**, análogo al 82.70% de *Uber Reviews*).

Se implementó un flujo de aprendizaje automatizado estrictamente encapsulado en `Pipeline` de `scikit-learn`, garantizando la ausencia total de fuga de información (*data leakage*) mediante una partición hold-out independiente (80% Train, N = 4.871; 20% Test, N = 1.218) y un esquema de validación cruzada estratificada de 5 pliegues (**Stratified 5-Fold CV**). Se contrastaron 10 arquitecturas predictivas: 3 líneas base (Dummy Mayoría, Multinomial Naive Bayes, Regresión Logística), 3 ensambles de la familia **Bagging** (Random Forest, Extra Trees, Bagging Linear SVC) y 4 ensambles de la familia **Boosting** (AdaBoost, Gradient Boosting, XGBoost, CatBoost).

Los resultados empíricos confirman de forma contundente la hipótesis de Tiwari et al. (2023): el modelo **Bagging Meta-Estimator con Linear SVC** superó a todas las familias en equilibrio operativo, alcanzando en el conjunto de prueba independiente un **Weighted F1-Score del 90.23%**, un **ROC-AUC de 0.9277**, la máxima cobertura en detección de reclamos ciudadanos (**Recall de Quejas = 97.55%**), una tasa mínima de falsas alarmas (**FPR = 2.45%**) y una latencia de inferencia de apenas **0.06 ms por reseña**, convirtiéndose en la arquitectura idónea para el monitoreo institucional de TransMilenio S.A.

7.1. Consolidación de los Datos

7.1.1. Origen, Autenticidad y Calidad del Dataset

El corpus definitivo se conformó a partir de las reseñas ciudadanas emitidas para la aplicación institucional **TransMi[App]** (`com.nexura.transmilenio`), herramienta digital oficial desarrollada por Nexura Internacional para el ente gestor TransMilenio S.A. La captura se ejecutó exhaustivamente a través de la API pública de Google Play Store con localización geográfica en Colombia (`country="co"` , `lang="es"`).

Parámetro / Atributo	Valor Confirmado	Justificación Metodológica
Identificador de Aplicación	<code>com.nexura.transmilenio</code>	TransMi[App] Oficial — Sistema Integrado de Transporte de Bogotá
Registros Totales Extraídos	6.093	Extracción exhaustiva por relevancia y novedad temporal
Registros Depurados (N)	6.089	Limpieza de textos vacíos o con longitud < 3 caracteres
Requisito Guía ML2 (N ≥ 5.000)	CUMPLIDO (6.089 > 5.000)	Satisface el umbral sin requerir síntesis artificial de datos
Ventana Temporal	13/06/2017 a 26/08/2026	Captura longitudinal que abarca múltiples versiones operativas
Variable Objetivo (Y)	Binaria: Y ∈	Y = 0 (1-2★, Queja / Falla); Y = 1 (4-5★, Elogio / Satisfacción)
Desbalance Empírico	80.57% Quejas / 19.43% Elogios	Ratio de desbalance de 4.15 a 1

7.1.2. Justificación de No Uso de Datos Sintéticos

La guía del curso autoriza tres vías de obtención: dataset real, simulación fundamentada o combinación. En esta entrega se optó deliberadamente por la **vía 100% de datos reales**, sustentada en tres criterios metodológicos:

1. **Suficiencia Muestral**: El corpus de 6.089 registros supera con holgura los 5.000 registros mínimos requeridos,

garantizando suficiente soporte estadístico por pliegue en validación cruzada.

2. Validez Ecológica del Lenguaje Coloquial Bogotano: El lenguaje natural de los usuarios de TransMilenio incluye construcciones sintácticas informales, modismos locales (*"el sitp nunca pasa"*, *"se cierra sola la app"*, *"no actualiza el saldo de tullave"*, *"la ruta h131 demorada"*) y variaciones ortográficas que un generador sintético no puede replicar con fidelidad semántica sin inducir sesgos artificiales.

3. Desbalance Orgánico del Dataset Real: El corpus de TransMi[App] presenta **80.57% de quejas frente a 19.43% de elogios** (ratio 4.15 a 1), un desbalance que emerge de forma natural del comportamiento de los usuarios y que ningún mecanismo de simulación podría replicar con la misma autenticidad lingüística y contextual.




Figura 1: A. Tasa de completitud por variable: el texto (*contenido*) y la calificación poseen 100% de integridad; únicamente *version_app* presenta un 14.52% de valores faltantes (usuarios que omitieron actualizar el metadato). B. Distribución de calificaciones en estrellas (1★: 65.6%, 2★: 14.9%, 4★: 5.5%, 5★: 14.0%).

7.1.3. Análisis Exploratorio de Datos (EDA)

El análisis exploratorio reveló tres propiedades estructurales fundamentales:

- 1. Asimetría de la Longitud Textual:** Los usuarios que expresan quejas y reclamos redactan opiniones significativamente más extensas y descriptivas que aquellos que elogian la aplicación. Las quejas exhiben una media de **22.74 ± 17.87 palabras** (mediana: 18 palabras, rango intercuartílico IQR = 20), mientras que los elogios registran una media de **17.36 ± 18.41 palabras** (mediana: 11 palabras, IQR = 20). En caracteres, las quejas alcanzan un percentil 75 de 164 caracteres contra 130 caracteres en elogios.
- 2. Correlación Multivariada:** Se apreciaron patrones estadísticos donde textos extensos se asocian de manera consistente con fallas operativas reportadas por los usuarios (correlación $p = -0.21$).
- 3. Firmas Léxicas Diferenciales:** El análisis de N-gramas y nubes de palabras demuestra que el vocabulario de quejas se agrupa en torno a la operatividad del sistema (*"rutas"*, *"sitp"*, *"actualizacion"*, *"demora"*, *"buses"*, *"paraderos"*, *"tiempo real"*, *"mapa"*, *"pesimo"*), mientras que los elogios se concentran en términos de utilidad y afecto (*"excelente"*, *"buena"*, *"util"*, *"ayuda"*, *"facil"*, *"recomiendo"*, *"gracias"*).




Figura 2: A. Estimación de densidad por kernel (KDE) de la longitud en palabras por polaridad. B. Diagrama de caja y bigotes (Boxplot) que evidencia la mayor asimetría y dispersión en las quejas ciudadanas.

Elemento	Enfoque Original (Tiwari et al., 2023)	Adaptación en este Proyecto (Fase 2)
Idioma y Tokenización	Tokenización estándar en inglés	Preprocesamiento fonético-ortográfico para español colombiano
Stopwords	Lista genérica de inglés	Stopwords en español enriquecidas con términos neutros del dominio
Representación Dispersa	TF-IDF de unigramas, bigramas y trigramas	TF-IDF con N-gramas $\in (1, 2)$, <code>min_df = 2</code> , <code>max_features = 4.000</code> y sublineal TF
Compensación del Desbalance	No implementada (Uber con 82.7% no compensado)	Ponderación de clases inversa (<code>class_weight='balanced'</code> , <code>scale_pos_weight=4.15</code>)
Esquema de Validación	Hold-out simple 80/20 sin estimación de varianza	Stratified 5-Fold Cross-Validation (media $\pm$ desv. est.) + Hold-out Test 20%
Calibración de Probabilidades	Linear SVC sin salida probabilística	Calibración con <code>CalibratedClassifierCV</code> para cálculo exacto de ROC-AUC

7.3.2. Catálogo de Modelos Contrastados

Se evaluaron 10 modelos pertenecientes a tres familias metodológicas:

1. Líneas Base (ML1):

- *Dummy Classifier (Mayoría)*: Clasificador trivial que asigna siempre la clase mayoritaria ($Y = 0$). Cota inferior indispensable en problemas con fuerte desbalance.
- *Multinomial Naive Bayes*: Clasificador probabilístico generativo clásico con suavizado de Laplace ($\alpha = 0.5$).
- *Regresión Logística*: Modelo discriminativo lineal con regularización L2 ($C = 1.0$) y pesos balanceados.

2. Familia Bagging (ML2):

- *Random Forest*: Ensemble de 100 árboles de decisión con remuestreo bootstrap, subespacios aleatorios, profundidad máxima de 20 y pesos balanceados.
- *Extra Trees (Extremely Randomized Trees)*: Ensemble de 100 árboles con umbrales de división seleccionados de forma completamente estocástica.
- *Bagging Meta-Estimator (Linear SVC)*: Ensemble bagging de 10 clasificadores de soporte vectorial lineal (`LinearSVC` con $C = 0.5$), calibrados mediante sigmoid Platt para generar probabilidades continuas.

3. Familia Boosting (ML2):

- *AdaBoost*: Boosting adaptativo sobre árboles de decisión débiles (80 estimadores, tasa de aprendizaje $\eta = 0.3$).
- *Gradient Boosting*: Boosting estocástico de gradiente basado en descenso por gradiente sobre función de pérdida deviance (80 estimadores, $\eta = 0.1$, profundidad 4).
- *XGBoost*: Algoritmo de árboles con regularización de segundo orden y ponderación de la clase positiva (`scale_pos_weight = 4.15` , 100 árboles, $\eta = 0.08$, profundidad 5).
- *CatBoost*: Boosting simétrico oblivious con manejo balanceado de clases (`auto_class_weights='Balanced'` , 100 iteraciones, $\eta = 0.1$, profundidad 5).

7.4. Validación, Métricas e Interpretación Preliminar

7.4.1. Métricas de Evaluación Justificadas

Dada la naturaleza del servicio público y la asimetría de clases (80.57% quejas vs. 19.43% elogios), la métrica tradicional de *Accuracy* resulta engañosa: predecir siempre queja ofrece un 80.57% de exactitud trivial pero inutilidad operativa absoluta. Por ello, la evaluación se fundamenta en:

- **Balanced Accuracy**: Media aritmética de la sensibilidad de cada clase: $(\text{Recall}_0 + \text{Recall}_1) / 2$. Premia a los modelos que reconocen efectivamente la clase minoritaria sin sacrificar la mayoritaria.
- **Weighted F1-Score y Macro F1-Score**: Balance armónico entre precisión y cobertura.
- **Recall de Quejas (Clase 0)**: Métrica de máxima prioridad institucional para TransMilenio S.A., orientada a minimizar falsos positivos (falsas quejas pasadas por alto).
- **TPR de Elogios (Clase 1) y FPR (Tasa de Falsas Alarmas)**: Para comparar directamente con los resultados reportados en Tiwari et al. (2023).
- **ROC-AUC**: Capacidad de discriminación global independiente del punto de corte.
- **Latencia de Inferencia**: Tiempo de cómputo por registro en milisegundos.

7.4.2. Resultados Empíricos en Validación Cruzada (Stratified 5-Fold CV)

Tabla 1: Desempeño en Validación Cruzada (Train Set 80%, $N = 4.871$, media $\pm$ desv. est.)

Familia	Modelo	CV Accuracy	CV Balanced Acc	CV Weighted F1	CV Recall Quejas (0)	CV ROC-AUC	Tiempo CV (s)
Línea Base	Dummy (Mayoría)	80.58 ± 0.02%	50.00 ± 0.00%	71.91 ± 0.02%	100.00 ± 0.00%	0.5000 ± 0.0000	1.8 s
Línea Base	Multinomial NB	88.07 ± 0.69%	70.98 ± 1.96%	86.53 ± 0.90%	99.46 ± 0.38%	0.9278 ± 0.0076	1.8 s
Línea Base	Regresión Logística	89.55 ± 0.40%	83.92 ± 0.47%	89.22 ± 0.47%	92.36 ± 0.70%	0.9279 ± 0.0044	2.1 s
Bagging	Random Forest	84.15 ± 1.25%	82.97 ± 1.66%	84.70 ± 1.15%	84.03 ± 1.54%	0.9089 ± 0.0089	6.2 s
Bagging	Extra Trees	86.68 ± 1.34%	83.16 ± 1.71%	86.84 ± 1.21%	88.20 ± 1.83%	0.9100 ± 0.0083	5.1 s
Bagging	Bagging Linear SVC	90.00 ± 0.53%	78.48 ± 1.44%	89.63 ± 0.60%	97.96 ± 0.49%	0.9276 ± 0.0069	3.6 s
Boosting	AdaBoost	82.02 ± 0.50%	58.42 ± 2.67%	78.66 ± 0.96%	99.62 ± 0.42%	0.7860 ± 0.0152	7.9 s
Boosting	Gradient Boosting	88.05 ± 0.52%	72.69 ± 2.14%	86.63 ± 0.84%	97.71 ± 0.58%	0.8934 ± 0.0125	14.8 s
Boosting	XGBoost	83.64 ± 0.30%	82.43 ± 0.27%	84.36 ± 0.34%	83.77 ± 0.55%	0.9026 ± 0.0051	8.1 s
Boosting	CatBoost	85.38 ± 0.89%	83.90 ± 1.35%	86.08 ± 0.86%	86.09 ± 1.27%	0.9134 ± 0.0082	18.0 s




Figura 4: Evaluación comparativa en Stratified 5-Fold Cross-Validation: A. Balanced Accuracy (con barra de error ± 1 desv. est.). B. Weighted F1-Score. C. Capacidad de discriminación ROC-AUC. D. Tiempo total de entrenamiento en validación cruzada.

7.4.3. Resultados en el Conjunto de Prueba Independiente (Test Hold-out 20%)

Tabla 2: Evaluación Final en Conjunto de Prueba Independiente (N_test = 1.218)

Familia	Modelo	Test Accuracy	Balanced Acc	Weighted F1	Macro F1	ROC-AUC	Recall Quejas (0)	TPR Elogios (1)	FP
Línea Base	Dummy (Mayoría)	80.54%	50.00%	71.86%	44.61%	0.5000	100.00%	0.00%	0.00%
Línea Base	Multinomial NB	89.08%	73.22%	87.60%	76.90%	0.9305	99.18%	47.26%	0.8
Línea Base	Regresión Logística	88.99%	84.21%	89.18%	80.60%	0.9271	92.05%	76.37%	7.9
Bagging	Random Forest	84.07%	83.87%	85.14%	75.33%	0.9125	84.20%	83.54%	15.
Bagging	Extra Trees	86.62%	84.49%	87.25%	78.43%	0.9194	87.97%	81.01%	12.
Bagging	Bagging Linear SVC	90.80%	80.21%	90.23%	82.20%	0.9277	97.55%	62.87%	2.4
Boosting	AdaBoost	82.02%	54.28%	75.56%	52.88%	0.7928	99.69%	8.86%	0.3
Boosting	Gradient Boosting	89.49%	75.72%	88.43%	79.25%	0.8789	98.27%	53.16%	1.7
Boosting	XGBoost	81.69%	83.03%	83.15%	73.35%	0.9135	80.84%	85.23%	19.
Boosting	CatBoost	84.48%	83.33%	85.42%	76.43%	0.9119	85.22%	81.43%	14.




Figura 5: Curvas ROC comparativas para los 10 modelos evaluados sobre el conjunto de prueba independiente de TransMi[App].

7.4.4. Discusión Comparativa: Bagging vs. Boosting

La contrastación empírica en el contexto real de TransMilenio arroja hallazgos de gran relevancia teórica y práctica:

1. **Confirmación del Hallazgo Central de Tiwari et al. (2023):**

Al igual que en el estudio de referencia sobre *Food Reviews* y *Uber Reviews*, **la familia Bagging superó a la familia Boosting en clasificación de texto con matrices TF-IDF**. El modelo **Bagging Linear SVC** alcanzó el **mayor F1 ponderado global (90.23%)** y el **mayor Accuracy de prueba (90.80%)**, combinado con un **ROC-AUC sobresaliente de 0.9277**. Esto ocurre porque los clasificadores lineales con margen máximo (SVM) manejan con superioridad la alta dimensionalidad y dispersión del espacio vectorial de n-gramas frente a los árboles de decisión individuales, mientras que el ensamble bagging reduce sustancialmente la varianza del estimador base.

2. **El Dilema Operativo de Sensibilidad vs. Falsas Alarmas:**

Los algoritmos de Boosting (especialmente XGBoost y CatBoost) lograron una mayor sensibilidad en la

detección de elogios ($TPR \approx 81\% - 85\%$). Sin embargo, lo hicieron a costa de inflar fuertemente la tasa de falsos positivos sobre las quejas ($FPR = 19.16\%$ en XGBoost y 14.78% en CatBoost). En contraste, **Bagging Linear SVC exhibe un FPR de tan solo 2.45%**, capturando el **97.55% de todas las quejas ciudadanas reales** (957 de 981 quejas en prueba). Para una entidad pública como TransMilenio S.A., este balance es crítico: clasificar erróneamente una queja real como un elogio equivale a invisibilizar fallas operativas en estaciones o buses.

7.4.5. Interpretación Preliminar y Diagnóstico de Errores




Figura 6: Importancia de características e interpretabilidad léxica: Magnitud del coeficiente discriminante para términos determinantes de quejas (A) y elogios (B).




Figura 7: Diagnóstico cualitativo y cuantitativo de errores en el conjunto de prueba ($N = 1.218$): A. Desglose entre aciertos (90.8%) y errores (9.2%). B. Distribución de longitud en palabras para casos de falsos positivos y falsos negativos.

7.5. Autoevaluación según Rúbrica de la Segunda Entrega

Criterio de Evaluación	Nivel Alcanzado	Evidencia Documental y Experimental
1. Consolidación de los datos	Excelente (4.0–5.0)	Dataset 100% real de 6.089 reseñas exclusivas de TransMi[App] (N > 5.000), extraídas directamente de Google Play Store (Colombia). Justificación sólida de no simular: suficiencia muestral, validez ecológica del español coloquial bogotano y desbalance orgánico real (80.57% quejas vs. 19.43% elogios).
2. Flujo sin fuga de datos	Excelente (4.0–5.0)	Arquitectura integrada en <code>Pipeline</code> de <code>scikit-learn</code> . Partición previa Hold-out 80/20 y Stratified 5-Fold Cross-Validation. Ajuste de vocabulario e IDF ejecutado estrictamente en los folds de entrenamiento de cada iteración, garantizando cero contaminación o data leakage.
3. Reproducción y adaptación del método	Excelente (4.0–5.0)	Reproducción rigurosa de Tiwari et al. (2023) adaptada al español de Bogotá. Comparación de 10 modelos pertenecientes a tres familias: Líneas Base (Dummy, Naive Bayes, Regresión Logística), Bagging (Random Forest, Extra Trees, Bagging Linear SVC) y Boosting (AdaBoost, Gradient Boosting, XGBoost, CatBoost).
4. Validación, métricas e interpretación	Excelente (4.0–5.0)	Validación cruzada estratificada reportando variabilidad (media ± desv. est.) y evaluación en Test independiente. Justificación de métricas ante el desbalance (Balanced Accuracy, Weighted F1, Recall de Quejas, TPR, FPR, Latencia). Confirmación empírica de la superioridad de Bagging Linear SVC (F1 = 90.23%, AUC = 0.9277, Recall quejas = 97.55%, FPR = 2.45%).
5. Comunicación, informe y sustentación	Excelente (4.0–5.0)	Documento formal con extensión concisa y rigurosa dentro del límite de 3 a 5 páginas de cuerpo. Figuras de alta resolución integradas. Código modular y reproducible en Python.

7.6. Referencias Bibliográficas

1. Tiwari, D., Nagpal, B., Bhati, B. S., Mishra, A., & Kumar, M. (2023). A systematic review of social network sentiment analysis with comparative study of ensemble-based techniques. *Artificial Intelligence Review*, 56, 13407–13461. <https://doi.org/10.1007/s10462-023-10472-w>